

PREPARAÇÃO DE DADOS

PLANILHAS DE DADOS

Ciências de Dados - Teoria do Aprendizado Estatístico
Profª. Márcia Roberta S. Pires Silva

Exemplo - Preparação de dados

Considere a planilha *morfina.xls* e tenha em mente que o objetivo do estudo, da Faculdade de Medicina da USP, foi avaliar a relação entre a quantidade de morfina administrada a pacientes com dores intensas, decorrentes de lesões medulares ou radiculares, e a concentração dessa substância em seus cabelos. Para isso, foram realizadas três medições em cada paciente: a primeira logo após o início do tratamento e as seguintes após 30 e 60 dias.

Detalhes podem ser obtidos no documento disponível no arquivo *morfina.doc*.

Preparação de Dados

A abordagem estatística para o tratamento de dados envolve:

- i) O planejamento da forma de coleta em função dos objetivos do estudo.
- ii) A organização de uma planilha para seu armazenamento eletrônico; no caso de megadados, a organização de um banco de dados.
- iii) O seu resumo por meio de tabelas e gráficos.
- iv) A identificação e correção de possíveis erros de coleta e/ou digitação.
- v) A proposta de modelos probabilísticos baseados na forma de coleta dos dados e nos objetivos do estudo; a finalidade desses modelos é relacionar a amostra a população para a qual se quer fazer inferência.

Preparação de Dados

- vi)** A proposta de modelos estruturais para os parâmetros do modelo probabilístico com a finalidade de representar relações entre as variáveis observadas.
- vii)** A avaliação do ajuste do modelo aos dados por meio de técnicas de diagnóstico e/ou simulação.
- viii)** A reformulação e reajuste do modelo à luz dos resultados do diagnóstico e/ou de estudos de simulação.
- ix)** A tradução dos resultados do ajuste em termos não técnicos.

Planilha de dados

Planilhas eletrônicas de dados são matrizes em que se armazenam dados com o objetivo de permitir sua análise estatística.

Cada linha da matriz de dados corresponde a uma unidade de investigação e cada coluna, a uma variável.

A primeira etapa da construção de uma planilha de dados consiste na elaboração de um dicionário com a especificação das variáveis, que envolve:

- i) sua definição operacional;
- ii) a atribuição de rótulos as variáveis (esses rótulos devem ser preferencialmente mnemônicos e grafados com letras minúsculas e sem acentos para facilitar a digitação e leitura por pacotes computacionais);

Planilha de dados

- iii) a especificação das unidades de medida ou definição de categorias; para variáveis categorizadas, convém atribuir valores numéricos as categorias com a finalidade de facilitar a digitação e evitar erros;
- iv) a atribuição de um código para valores omissos (missing);
- v) a indicação de como devem ser codificados dados abaixo do limite de detecção;
- vi) a especificação do número de casas decimais;

Planilha de dados

vii) a indicação, quando pertinente, de limites (inferiores ou superiores) para facilitar a identificação de erros; por exemplo, o valor mínimo para aplicação num fundo de ações é de R\$ 2000,00;

viii) o mascaramento (por meio de um código de identificação, por exemplo) de informações sigilosas ou confidenciais como o nome de pacientes de ensaios clínicos.

Planilha de dados

Algumas recomendações para a construção de planilhas eletrônicas de dados são:

- i)** não utilizar limitadores de celas (borders) ou cores;
- ii)** reservar a primeira linha para os rótulos das variáveis;
- iii)** não esquecer uma coluna para a variável indicadora das unidades de investigação (evitar informações confidenciais como nomes de pacientes);
- iv)** escolher ponto ou vírgula para separação de casas decimais;
- v)** especificar o número de casas decimais;
- vi)** formatar as celas correspondentes a datas para manter a especificação uniforme (dd/mm/aaaa ou mm/dd/aaaa, por exemplo).

Exemplo

Consideremos os dados extraídos de um estudo realizado no Instituto de Ciências Biomédicas da Universidade de São Paulo com o objetivo de avaliar a associação entre a infecção de gestantes por malária e a ocorrência de microcefalia nos respectivos bebês. O dicionário das variáveis observadas é apresentado a seguir.

Estudo publicado no [Jornal da USP](#), data 21/11/2018.

Planilha dos dados para a construção do dicionário das variáveis

ident	idade	nummal	parasita	numgest	idgest	sexorn	pesorn	estrn	pcefal
1	25	0	0	3	38	2	3665	46	36
2	30	0	0	9	37	1	2880	44	33
3	40	0	0	1	41	1	2960	52	35
4	26	0	0	2	40	1	2740	47	34
5	.	0	0	1	38	1	2975	50	33
6	18	0	0	.	38	2	2770	48	33
7	20	0	0	1	41	1	2755	48	34
8	15	0	0	1	39	1	2860	49	32
9	.	0	0	.	42	2	3000	50	35
10	18	0	0	1	40	1	3515	51	34
11	17	0	0	2	40	1	3645	54	35
12	18	1	1	3	40	2	2665	48	35
13	30	0	0	6	40	2	2995	49	33
14	19	0	0	1	40	1	2972	46	34
15	32	0	0	5	41	2	3045	50	35
16	32	0	0	8	38	2	3150	44	35
17	18	0	0	2	40	1	2650	48	33.5
18	18	0	0	1	41	1	3200	50	37
19	19	0	0	1	39	1	3140	48	32
20	18	0	0	2	40	1	3150	47	35
21	27	0	0	3	40	1	4185	52	35.5
22	26	0	0	3	40	2	4070	52	35
23	.	0	0	.	40	1	3950	50	37
24	19	0	0	1	40	1	3245	51	33
25	23	0	0	.	41	1	3010	49	35
26	.	0	0	.	40	2	3260	50	33
27	20	1	1	2	40	2	3450	49	33
28	19	0	0	3	40	2	2765	48	32
29	22	0	0	4	40	1	4190	50	34
30	32	0	0	4	42	2	4035	51	34
31	33	0	0	5	39	2	3620	51	33
32	30	3	3	5	38	1	3230	48	34
33	36	0	0	7	39	2	3185	50	38
34	.	0	0	.	39	2	2950	47	33

Exemplo do dicionário das variáveis

Rótulos	Variável	Unidade de medida
idade	Idade da mãe	anos
nummal	Quantidade de malárias durante a gestação	número inteiro
parasita	Espécie do parasita da malária	0: não infectada
		1: P. vivax
		2: P. falciparum
		3: malária mista
		4: indeterminado
numgest	Paridade (quantidade de gestações)	Número inteiro
idgest	Idade gestacional no parto	semanas
sexorn	Sexo do recém-nascido	1: masculino
		2: feminino
pesorn	Peso do recém-nascido	g
estrn	Estatura do recém-nascido	cm
pcefal	Perímetro cefálico do recém-nascido	cm
Obs:	Observações omissas são representadas por um ponto	

Exemplo do dicionário das variáveis

Rótulos	Variável	Unidade de medida
idade	Idade da mãe	anos
nummal	Quantidade de malárias durante a gestação	número inteiro
parasita	Espécie do parasita da malária	0: não infectada
		1: P. vivax
		2: P. falciparum
		3: malária mista
		4: indeterminado
numgest	Paridade (quantidade de gestações)	Número inteiro
idgest	Idade gestacional no parto	semanas
sexorn	Sexo do recém-nascido	1: masculino
		2: feminino
pesorn	Peso do recém-nascido	g
estrn	Estatura do recém-nascido	cm
pcefal	Perímetro cefálico do recém-nascido	cm
Obs:	Observações omissas são representadas por um ponto	

Obrigada e até a próxima aula!