

ANÁLISE DESCRITIVA DE DADOS

VARIÁVEIS QUALITATIVAS E QUANTITATIVAS

Ciências de Dados - Teoria do Aprendizado Estatístico
Profª. Márcia Roberta S. Pires Silva

Repositório de arquivos no GitHub

Os arquivos de *scripts* apresentados nas aulas estão públicos no repositório da disciplina no GitHub.

Disponível em: https://github.com/mrspires/TAE_Repositorio

Análise Estatística - Variáveis qualitativas

Variáveis qualitativas são aquelas variáveis que indicam qualidades, atributos, características não numéricas de forma geral.

- Qualitativas nominais: São aquelas que não permitem uma ordenação natural.
- Qualitativas ordinais: Por sua vez, são aquelas que admitem uma ordenação natural.

Técnica de resumo para análise estatística

Distribuição de frequências são apresentadas em forma de tabela, associa os valores da variável com suas frequências de ocorrência.

Análise Estatística - Tipos de frequências

Frequência absoluta (fa): representa o número de vezes que um valor (ou intervalo) ocorre nos dados.

Frequência relativa (fr): representa, em forma decimal, a proporção de ocorrências de um valor em relação ao tamanho da massa de dados,

$$fr = \frac{fa}{n}$$

Frequência percentual (fp): representa, em forma percentual, a proporção de ocorrências de um valor em relação ao tamanho da massa de dados,


$$fp = fr \times 100$$

Construção das distribuição de frequências e representação gráfica

As funções *table()* constrói a tabela de frequências absolutas; *prop.table()* constrói a tabela de frequências relativas e *cumsum()* a frequência acumulada dos dados da variável em questão.

O gráfico de barras e colunas são feitos com a mesma função *barplot()*. A única diferença é o argumento *horiz*, que deve ser verdadeiro no caso das barras.

Análise Estatística - [Exemplo](#)



Fluência ingles	Contagens	% do Total	% acumulada
algun	26	54.2%	54.2%
fluyente	20	41.7%	95.8%
nenhum	2	4.2%	100.0%

Análise Estatística - Variáveis quantitativas

Variáveis quantitativas são aquelas variáveis que exprimem quantidades sejam elas discretas ou contínuas.

Técnicas de resumo para análise estatística

- ❖ Distribuições de frequências absolutas, relativas e acumuladas (se necessário)
- ❖ Medidas de resumo
 - **posição:** média, mediana, moda, quartis
 - **dispersão:** variância populacional e amostral, desvio padrão e médio, amplitude interquartis
 - **forma:** assimetria e curtose

Análise Estatística - Técnicas de resumo

- ❖ Representação gráfica relativa a técnica de resumo aplicada:
 - **Gráfico de dispersão:** relativo às medidas de resumo de dispersão apresentadas
 - ***Boxplot:*** relativo às medidas de resumo de posição
 - **Histograma:** relativo às distribuições de frequência e medidas de resumo de forma

Análise Estatística - Distribuição de frequências

Construção da tabela de distribuição de frequências

Para as variáveis quantitativas discretas ou contínuas que apresentarem muitos valores, geralmente, têm-se a necessidade de agrupar esses valores em classes. Dessa forma, obtendo as distribuições de frequências em cada classe. Para determinar o número de classes (k) para cada variável têm-se:

Critério empírico	Critério de Scott (1979)
$k \simeq \begin{cases} \sqrt{n}, & \text{se } n < 100 \\ 5 \log n, & \text{se } n > 100 \end{cases}$	$k \simeq 1 + \frac{An^{1/3}}{3,495}$

n : número de elementos da amostra

A representação gráfica da distribuição de frequências, sejam variáveis quantitativas discretas será o gráfico de barras. Para as variáveis quantitativas contínuas, se dará por meio do histograma. A rotina para construir histogramas usa a função *hist()*.

Análise Estatística - Exemplo

Anos de formado	Freq. Absoluta	Freq. Relativa	Freq. Acumulada
NA	2	4%	4%
0 — 3	27	54%	58%
4 — 7	12	24%	82%
8 —11	8	16%	98%
12 — 15	1	2%	100%
Totais	50	100%	



Análise estatística - Medidas de resumo de posição

As medidas de posição indicam a posição global dos dados na escala de valores possíveis. E são elas: mínimo, máximo, mediana (md), moda, quartis (Q) e média ($\bar{x}$)

$$\text{md}(x) = \begin{cases} x_{(\frac{n+1}{2})}, & \text{se } n \text{ for ímpar,} \\ \frac{1}{2}[x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}], & \text{se } n \text{ for par.} \end{cases}$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$Q(p) = \begin{cases} x_{(i)}, & \text{se } p = p_i = (i - 0,5)/n, \quad i = 1, \dots, n \\ (1 - f_i)Q(p_i) + f_iQ(p_{i+1}), & \text{se } p_i < p < p_{i+1} \\ x_{(1)}, & \text{se } 0 < p < p_1 \\ x_{(n)}, & \text{se } p_n < p < 1, \end{cases}$$

Funções das medidas de resumo de posição

A função *summary()* apresenta as medidas: mínimo (*min*), 1º quartil (*1st Qu*), mediana (*median*), média (*mean*), 3º quartil (*3rd Qu*) e máximo (*max*) dos dados da variável em questão. Apenas a moda não se encontra implementada nos comandos básicos do R.

A representação gráfica ajustada para essas medidas é o *boxplot* e a função para plotá-lo é *boxplot()*.


Boxplots

O **boxplot** é baseado nos quantis e serve para resumir a distribuição de dados.

Sua representação é a partir de um retângulo:

- base determinada por Q1 e Q3;
- um segmento de reta que corresponde a posição da mediana;
- e dois segmentos de reta (bigodes) colocados respectivamente acima e abaixo de Q1 e Q3 com limites inferior e superior com d_Q representando a distância interquartis;
- pontos colocados acima do limite superior ou abaixo do limite inferior, são os valores atípicos ou discrepantes representados por *, por exemplo.

Boxplot



Q1: 1o quartil Q3: 3o quartil DQ: distância interquartis M: mediana

Análise dos *boxplots*


O gráfico *boxplot* permite a identificação da posição dos 50% centrais dos dados, a posição da mediana, os valores atípicos, se existirem, permitindo a avaliação da simetria da distribuição.

Os *boxplots* são úteis para a comparação de vários conjuntos de dados.

Análise Estatística - Exemplo

Estatística Descritiva

	salario (R\$)
N	49
Média	2799
Mediana	2500
Moda	2000
Desvio-padrão	1440
Variância	2.07e+6
Amplitude	6200
Mínimo	800
Máximo	7000



Obrigada e até a próxima aula!