

ANÁLISE DE DADOS DE DUAS VARIÁVEIS

Ciências de Dados - Teoria do Aprendizado Estatístico
Profª. Márcia Roberta S. Pires Silva

Análise descritiva da associação entre duas variáveis

É possível dizer que existe **associação** entre **duas variáveis** se o conhecimento do valor de uma delas nos dá alguma informação sobre alguma característica da distribuição da outra.

Como na análise de uma única variável, também representaremos a distribuição conjunta das variáveis de interesse por meio de tabelas e gráficos, além de avaliarmos as medidas de resumo e a magnitude da sua associação nos três casos:

1. as duas variáveis são qualitativas;
2. as duas variáveis são quantitativas;
3. uma variável é qualitativa e a outra quantitativa.

Técnicas de análise descritiva entre duas variáveis

As técnicas são distintas para analisar os dados de duas variáveis:

- Para **duas variáveis qualitativas**, a análise é baseada no número de unidades de investigação em cada casela de uma tabela de dupla entrada e também, nas técnicas para medir a associação entre as variáveis;
- Para **duas variáveis quantitativas**, as observações são obtidas por mensurações, técnicas para medir a correlação entre as variáveis e técnicas envolvendo gráficos de dispersão e boxplots;
- E para **uma variável qualitativa e a outra quantitativa**, serão comparadas as distribuições da variável quantitativa para cada categoria da variável qualitativa e técnicas para as medidas de resumo e representação gráfica dessas medidas.

Técnicas de análise descritiva entre duas variáveis

Em qualquer uma das técnicas de análise de dados de duas variáveis vale salientar que é importante considerar a classificação das variáveis segundo outra característica que está ligada a forma em que os dados foram coletados, logo:

- **Variáveis preditoras** ou **explicativas** são aquelas cujas características ou valores são fixos, seja por planejamento ou por condicionamento;
- **Variáveis resposta** são aquelas cujas categorias ou valores são aleatórios.

Exemplo - Característica de variáveis

No estudo em que se deseja avaliar o efeito do tipo de aditivo adicionado ao combustível no consumo em automóveis, cada um de 3 conjuntos de 5 automóveis, de mesmo modelo, foi observado sob o tratamento com um de 4 tipos de aditivos. O consumo, em km/L, foi avaliado após um determinado período de tempo.

A variável qualitativa "Tipo de aditivo" é considerada como **explicativa** e a variável quantitativa "Consumo de combustível" é classificada como **resposta**.

Análise de duas variáveis qualitativas

As classes das duas variáveis podem ser organizadas numa tabela de dupla entrada, onde as linhas correspondem aos níveis de uma variável e as colunas aos níveis da outra.

Para exemplificar vamos considerar as variáveis qualitativas Nível de Instrução (*Inst*) e Estado Civil (*Est.civil*) do arquivo *milsa.csv*.

Exemplo - Análise de duas variáveis qualitativas

Estado Civil	Nível de Instrução			
	1º grau	2º grau	Superior	Total
Casado	5	12	3	20
Solteiro	7	6	3	16
Total	12	18	6	36

Análise de duas variáveis qualitativas

Para obter a tabela de dupla entrada ou tabela de contingência, usa-se a função *table()*. Deve-se colocar a extensão da tabela com os totais nas marginais, para isso usa-se a função *addmargins()*.

Já as tabelas de frequências relativas são obtidas com a função *prop.table()*, mas existem três possibilidades em cada casela:

- Em relação ao total geral;
- Em relação aos totais por linha (*margin = 1*)
- Em relação aos totais por coluna (*margin = 2*)

Exemplo - Análise de duas variáveis qualitativas

Na tabela abaixo estão as frequências relativas correspondentes a tabela anterior:

Estado Civil	Nível de Instrução			
	1º grau	2º grau	Superior	Total
Casado	0,1388889	0,333333	0,083333	0,555556
Solteiro	0,194444	0,166667	0,083333	0,444444
Total	0,333333	0,5	0,166667	1

Exemplo - Análise de duas variáveis qualitativas

Nas tabelas abaixo estão as porcentagens em relação ao total:

Colunas (Nível de Instrução)

Estado Civil	Nível de Instrução		
	1º grau	2º grau	Superior
Casado	0,2500	0,6000	0,1500
Solteiro	0,4375	0,3750	0,1875

Linhas (Estado Civil)



Estado Civil	Nível de Instrução		
	1º grau	2º grau	Superior
Casado	0,4167	0,6667	0,5000
Solteiro	0,5833	0,3333	0,5000

Exemplo - Análise de duas variáveis qualitativas

Os gráficos representativos das tabelas de dupla entrada apresentadas são construídos a partir das funções: *barplot()* e *par()*,

A função *par()* aceita uma série de argumentos que controlam diferentes aspectos dos gráficos, tais como layout, margens, aparência dos eixos, cores, entre outros. E a função *barplot()* plota o gráfico de barras.

Exemplo - Análise de duas variáveis qualitativas



Análise de duas variáveis qualitativas

Para o efeito de comparação com outros estudos envolvendo as mesmas variáveis mas com totais de pesquisados diferentes, convém expressar a partir das frequências relativas que exprimem porcentagens.

A análise textual para duas variáveis qualitativas deve ser realizada a partir da verificação a medida de **associação** entre as variáveis de estudo com o cálculo do **coeficiente de contingência**.

A seguir, para RELEMBRAR, tem-se a classificação da associação das variáveis e o exemplo para cálculo do coeficiente de contingência.

Medidas de associação entre variáveis qualitativas

Existem muitas medidas que quantificam a associação entre variáveis qualitativas, uma delas é o *coeficiente de contingência*.

O intervalo do coeficiente = [0 ; 1]

Classificação

- igual a zero, indica a **ausência de associação**;
- menor que 0,5 - indica uma **fraca associação**;
- maior que 0,5 - indica uma **forte associação**;
- igual a 1 - indica uma **perfeita associação**.

Medidas de associação entre variáveis qualitativas - Exemplo

Queremos verificar se a criação de determinado tipo de cooperativa está associada com algum fator regional. Dados observados relevantes está na tabela a seguir:

Estado	Tipo de Cooperativa				Total
	Consumidor	Produtor	Escola	Outras	
São Paulo	214 (33%)	237 (37%)	78 (12%)	119 (18%)	648 (100%)
Paraná	51 (17%)	102 (34%)	126 (42%)	22 (7%)	301 (100%)
Rio G. do Sul	111 (18%)	304 (51%)	139 (23%)	48 (8%)	602 (100%)
Total	376 (24%)	643 (42%)	343 (22%)	189 (12%)	1551 (100%)

Dados esperados está na tabela a seguir:

Estado	Tipo de Cooperativa				Total
	Consumidor	Produtor	Escola	Outras	
São Paulo	156 (648 . 24%)	272	142	78	648
Paraná	72 (301 . 24%)	127	66	36	301
Rio G. do Sul	144 (602 . 24%)	254	132	72	602
Total	376 (24%)	643 (42%)	343 (22%)	189 (12%)	1551 (100%)

A tabela a seguir apresenta em cada casela a medida do desvio $\frac{(o_i - e_i)^2}{e_i}$

Estado	Tipo de Cooperativa			
	Consumidor	Produtor	Escola	Outras
São Paulo	21,56	4,50	28,84	21,55
Paraná	6,12	4,92	54,54	5,44
Rio G. do Sul	7,56	9,84	0,37	8,00

Medidas de associação entre variáveis qualitativas

A medida de afastamento global pode ser dada pela soma de todas as medidas dos desvios, denominada χ^2 (Qui-quadrado) de *Pearson*, e pelo exemplo teríamos:

$$\chi^2 = 21,56 + 6,12 + \dots + 5,44 + 8,00 = 173,24$$

O **coeficiente de contingência** é calculado por $C = \sqrt{\frac{\chi^2}{\chi^2 + n}}$

Pelo exemplo, temos **$C = 0,3170 \Rightarrow$ fraca associação**

Associação de duas variáveis qualitativas

Em R, tem-se duas formas de obter o **coeficiente de contingência**, porém em ambas deve-se gerar a tabela de contingência.

Pode-se fazer o cálculo aplicando a fórmula do coeficiente de contingência, que é baseada no valor do **Qui-quadrado**, sendo a função para obtê-lo é *chisq.test()*, e a fórmula

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}}$$

Ou calcula diretamente utilizando-se a função *ContCoef()* do pacote *DescTools*.

Obrigada e até a próxima aula!