

CONTINUAÇÃO DA ANÁLISE DE DADOS DE DUAS VARIÁVEIS

Ciências de Dados - Teoria do Aprendizado Estatístico
Profª. Márcia Roberta S. Pires Silva

Análise descritiva entre uma variável quantitativa e outra qualitativa

A técnica para a análise de uma variável qualitativa e a outra quantitativa, será por meio do conceito de **ganho relativo na variância**, também conhecido como **coeficiente de determinação R^2** . Esse coeficiente representa a proporção da variância da variável resposta que é explicada pela variável preditiva.

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

Medida de associação entre variáveis qualitativas e quantitativas

Onde:

- SS_{res} é a **soma dos quadrados dos resíduos**, também chamada de soma dos quadrados dos erros. Dada por

$$SS_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- SS_{tot} é a **soma total dos quadrados**. Dada por

$$SS_{tot} = \sum_{i=1}^n (y_i - \bar{y})^2$$

Medida de associação entre variáveis qualitativas e quantitativas

A medida que quantifica a associação entre variáveis qualitativas e quantitativas é o *coeficiente de determinação* (R^2) e o intervalo é $0 \leq R^2 \leq 1$, onde:

- $R^2 = 0$, significa que o modelo não explica **nenhuma variação dos dados**;
- $R^2 = 1$, significa que o modelo explica **perfeitamente a variação dos dados**.

Se o valor de R^2 estiver próximo de 1, isso indica que o modelo ajustado explica bem a variação dos dados.

Medidas descritivas para variável quantitativa e qualitativa

A função para definir as classes de uma variável quantitativa de acordo com as medidas dos os quartis é a *cut()*, com o argumento *include.lowest = TRUE*.

O argumento *include.lowest* garante que todos os dados estarão nas classes, inclusive o menor (mínimo) na primeira classe, pois o comum é que os intervalos sejam abertos à esquerda.

Medidas descritivas para variável quantitativa e qualitativa

Por conta do *boxplot* deve-se apresentar as medidas descritivas, sendo o usual obter um resumo da variável quantitativa como mostrado anteriormente, porém agora teremos essas medidas de resumo para cada categoria qualitativa de interesse.

Será utilizada a função *tapply()* porque ela divide as estruturas de dados e aplica funções a cada subconjunto. Essa função calcula algumas estatísticas descritivas, tais como: média, mediana, desvio padrão, mínimo e máximo.

Análise descritiva entre uma variável quantitativa e outra qualitativa

Para trabalhar com uma variável categórica e uma quantitativa deve usar a função `aov()` para ajustar um modelo de ANOVA e calcular o R^2 , o que indicaria quanto da variância na variável resposta é explicada pela variável preditiva (categórica).

Análise descritiva para duas variáveis quantitativas

As técnicas para a análise de duas variáveis quantitativas, serão as observações obtidas por mensurações, técnicas para medir a correlação entre as variáveis e técnicas envolvendo medidas e gráfico de dispersão.

Para ilustrar vamos considerar as variáveis *Salario* e *Anos* do arquivo *milsa.csv*.

Como anteriormente fora realizado, deve-se agrupar as duas variáveis em classes definidas (função *cut()*) pelos respectivos quartis. Isso gerará uma tabela de cruzamento de 4 linhas e 4 colunas.

Gráfico para duas variáveis quantitativas


O gráfico adequado para representar duas variáveis quantitativas é um gráfico de dispersão.

Note que se as variáveis envolvidas puderem ser classificadas como “explicativa” e “resposta” devemos colocar a primeira no eixo X e a segunda no eixo Y.

Neste exemplo é razoável admitir que a idade deve explicar, ao menos parcialmente, o salário e portanto fazemos o gráfico com idade no eixo X. Note que na função `plot( )`, podemos usar tanto os argumentos `x` e `y`, quanto o formato de fórmula, como visto anteriormente.

Gráfico para duas variáveis quantitativas

Gráfico de Dispersão



Associação de duas variáveis quantitativas

Para quantificar a associação entre duas variáveis desse tipo, usamos o **coeficiente de correlação**.

A função *cor()* possui três tipos de coeficientes de correlação:

1. **Correlação de Pearson**, para duas ou mais variáveis quantitativas;
2. **Correlação de Spearman**, para duas ou mais variáveis qualitativas ordinais e quantitativas;
3. **Correlação de Kendal**, para duas ou mais variáveis qualitativas ordinais.

Medidas de associação entre variáveis quantitativas

Para RELEMBRAR e ajudar na análise textual tem-se a definição classificação da correlação das variáveis quantitativas.

Definição de correlação

Os dados podem ser representados por pares ordenados $(\mathbf{x}, \mathbf{y})$, onde $\mathbf{x}$ é a variável independente (ou explicativa) e $\mathbf{y}$ é a variável dependente (ou resposta).

Coeficiente de correlação

A representação gráfica das variáveis ajuda muito a compreender o comportamento em conjunto das duas variáveis quanto à existência ou não de associação entre elas.

É muito útil a quantificação desta associação e a mais simples de representação é a linear. Isto é, iremos definir uma medida que avalia o quanto a nuvem de pontos no gráfico de dispersão aproxima-se de uma reta.

Coeficiente de correlação

O coeficiente de correlação é definido de modo a variar num intervalo finito, especialmente, de $[-1, 1]$.

Classificação

- igual a zero, indica a **ausência de correlação**;
- menor que 0,5 (negativo ou positivo), indica uma **fraca correlação**;
- maior que 0,5 (negativo ou positivo), indica uma **forte correlação**;
- igual a 1 (negativo ou positivo), indica uma **perfeita correlação**.

Obrigada e até a próxima aula!